



Facultad de Ingenierías
Análisis Multivariado
Maestría en Inteligencia Artificial y Ciencia de Datos
Prof. Cristian E. Garcia.



Condiciones:

- Subir la tarea en formato pdf a la plataforma UAO-Virtual.
- Es necesario incluir el código en R, Python o Julia. Mostrar los resultados mediante tablas, gráficos o indicadores que les permitan responder a los planteamientos.
- Deben interpretar los resultados obtenidos en cada situación según el contexto.
- Realizar la actividad en grupos de hasta 4 personas.



Desafío 2

Situación 1

Se dispone de un conjunto de [datos \(link\)](#) multivariados ($n = 200, p = 3000$) proveniente de la evaluación de un Modelo de Lenguaje de Gran Escala (LLM), NLA-7B. Las n observaciones corresponden a *prompts* (consultas) únicos, mientras que las p variables representan un conjunto heterogéneo de métricas (activaciones internas, evaluaciones humanas, y medidas de rendimiento derivadas).

El dataset exhibe una problemática severa de alta dimensionalidad ($p \gg n$), lo cual invalida la aplicación directa de métodos multivariados clásicos.

El estudio persigue un doble objetivo:

1. Validar psicométricamente un sub-instrumento de 20 ítems de evaluación humana, cuya estructura teórica postula cuatro constructos latentes (Calidad, Seguridad, Creatividad, Sesgo).
2. Implementar una estrategia de **Análisis Factorial-Cluster (Factor-Cluster Analysis)** para identificar perfiles tipológicos (clústeres) de los *prompts* basados en la totalidad de las $p = 3000$ variables, superando el desafío $p \gg n$.

Validación de la Estructura del Instrumento:

- Aísle el subconjunto de $p = 20$ variables correspondientes a la evaluación humana.

- Especifique el modelo de medición de cuatro factores (Calidad, Seguridad, Creatividad, Sesgo) basado en la hipótesis teórica.
- Estime el modelo y evalúe la bondad de ajuste (e.g., RMSEA, CFI, SRMR, χ^2). Concluya sobre la validez de constructo del instrumento.

Reducción de Dimensionalidad y Extracción de Características (EFA/PC):

- Considerando la matriz de datos completa (200×3000), discuta formalmente las implicaciones de la condición $p \gg n$ sobre la estimación de la matriz de covarianza (singularidad) y la inestabilidad de métodos como Máxima Verosimilitud.
- Implemente un Análisis Factorial Exploratorio utilizando el método de **Componentes Principales (PC)** para la extracción factorial, justificando su idoneidad y estabilidad computacional en este contexto.
- Determine el número de factores/componentes (m) a retener, utilizando el **Gráfico de Sedimentación (Scree Plot)** y el criterio de varianza explicada acumulada.
- Rote la solución factorial (e.g., Varimax) y genere la matriz de **puntuaciones factoriales** ($n \times m$), la cual servirá como el nuevo espacio de características de baja dimensión.

Identificación de Tipologías:

- Utilizando la matriz de puntuaciones factoriales ($200 \times m$) como entrada, justifique la superioridad de este enfoque (Análisis Factorial-Cluster) frente al clustering sobre el espacio original de $p = 3000$.
- Aplique un algoritmo de particionamiento (K-Means) y un método jerárquico aglomerativo (e.g., Método de Ward) sobre el espacio m -dimensional.
- Determine el número óptimo de clústeres (k) (vía Coeficiente de Silueta y análisis del dendrograma) y seleccione la solución de particionamiento más robusta.

Caracterización e Interpretación de Perfiles:

- Para la solución de k clústeres seleccionada, realice el perfilado de cada conglomerado. Calcule los centroides (medias) de las puntuaciones factoriales (m dimensiones) para cada clúster.
- Interprete el significado conceptual de cada clúster en el contexto del problema (e.g., "Perfil 1: Prompts de alta creatividad y alto riesgo de sesgo", "Perfil 2: Prompts de alta calidad factual y baja complejidad interna").
- Sintetice los hallazgos en un informe, discutiendo las implicaciones de estas tipologías para el *fine-tuning* y la evaluación del modelo NLA-7B.

Situación 2

En la evaluación de modelos de lenguaje de gran escala, un desafío central es determinar si las métricas de rendimiento capturan dimensiones cognitivas *genuinamente distintas* o si reflejan un único factor de inteligencia general latente. El proyecto **Open LLM Leaderboard** (HuggingFace, 2024) es la iniciativa de referencia global para abordar este problema de forma sistemática y comparable entre cientos de modelos.

El método del Leaderboard consiste en una evaluación estandarizada donde cada modelo de lenguaje es sometido a una batería de benchmarks públicos. Cada benchmark corresponde a una *tarea* específica (razonamiento lógico, conocimiento factual, seguimiento de instrucciones, etc.). El conjunto de datos final no es el texto generado por el modelo, sino la **cuantificación de su desempeño**: la puntuación obtenida (entre 0 y 100) en cada uno de esos benchmarks. Cada fila del dataset es un modelo evaluado, y cada columna representa una puntuación observable.

La Teoría (El Modelo a Validar)

Una teoría dominante en la investigación sobre capacidades de LLMs postula que el desempeño observable en benchmarks no es unidimensional. La hipótesis establece que las puntuaciones reflejan **tres constructos latentes independientes**:

1.Factor de Razonamiento (F_{raz}): La capacidad de inferencia formal, deducción multi-paso y resolución de problemas matemáticos complejos. No depende de memorización, sino de la habilidad para encadenar pasos lógicos ante problemas nuevos.

2.Factor de Conocimiento Factual (F_{con}): La amplitud y precisión del conocimiento declarativo codificado en los parámetros del modelo, abarcando desde ciencias naturales hasta conocimiento profesional especializado.

3.Factor de Alineamiento (F_{ali}): La capacidad del modelo para seguir instrucciones de manera precisa, mantener respuestas veraces y comportarse de forma útil y coherente en contextos de diálogo multi-turno, resultado del entrenamiento con feedback humano (RLHF).

Su tarea es utilizar CFA para **validar si esta teoría de tres factores latentes se ajusta** a los datos de desempeño empírico del Open LLM Leaderboard.

Fuente de Datos

Dataset: [Open LLM Leaderboard v2](#) — [HuggingFace](#)

Este conjunto de datos evalúa cientos de modelos de lenguaje abiertos en seis benchmarks estandarizados. Cada fila es un modelo en una versión específica de evaluación. Las columnas de interés son las puntuaciones en los benchmarks individuales, que representan las **variables observadas** ($X_1, \dots, X_9$).

Nota de acceso: el dataset puede descargarse directamente desde la interfaz del Leaderboard (opción Download) o consultarse vía la API de HuggingFace Datasets: `datasets.load_dataset("open-llm-leaderboard/results")`.

Preparación y Subconjunto de Datos

•**Filtre el dataset:** utilice únicamente modelos con evaluación completa (sin valores faltantes en los benchmarks seleccionados) y con al menos **7B parámetros**, para trabajar sobre una población comparable de modelos de escala mediana-grande. Se sugiere un subconjunto de $n \geq 150$ modelos.

•**Excluya duplicados:** algunos modelos aparecen en múltiples versiones de cuantización (e.g., fp16, int8, int4). Conserve únicamente la versión en precisión completa (fp16) de cada modelo base.

•**Seleccione las siguientes variables observadas (indicadores)** para su modelo, según la tabla:

Factor latente hipotetizado	(Variable X)	Columnas	Descripción	Carga esperada
F_raz (Razonamiento)	X_1	bbh	Big-Bench Hard: razonamiento de sentido común y lógica compleja ante tareas novedosas	Positiva (+)
F_raz (Razonamiento)	X_2	gsm8k	GSM8K: resolución de problemas matemáticos escolares formulados en lenguaje natural	Positiva (+)
F_raz (Razonamiento)	X_3	musr	MuSR: razonamiento multi-paso sobre narrativas largas que requieren inferencia causal	Positiva (+)
F_con (Conocimiento)	X_4	mmlu_pro	MMLU-Pro: conocimiento factual multi-dominio a nivel profesional (medicina, derecho, ciencias)	Positiva (+)
F_con (Conocimiento)	X_5	gpqa	GPQA: preguntas de ciencias naturales a nivel de posgrado (Graduate-Level Questions)	Positiva (+)

F_con (Conocimiento)	$\mathbf{x}_6$	arc_challenge	ARC-Challenge: preguntas de ciencias escolares de alta dificultad del conjunto ARC	Positiva (+)
F_ali (Alineamiento)	$\mathbf{x}_7$	ifeval	IFEval: seguimiento preciso de instrucciones estructuradas con restricciones verificables	Positiva (+)
F_ali (Alineamiento)	$\mathbf{x}_8$	truthfulqa	TruthfulQA: veracidad de respuestas en preguntas propensas a alucinación o sesgo popular	Positiva (+)
F_ali (Alineamiento)	$\mathbf{x}_9$	mt_bench	MT-Bench: calidad del diálogo en conversaciones multi-turno, evaluada por un LLM-juez externo	Positiva (+)

Especificación y Estimación del CFA

1.Especifique el modelo: defina un modelo CFA de tres factores (F_{raz} , F_{con} y F_{ali}) usando las 9 variables indicadoras de la tabla anterior, respetando estrictamente la asignación teórica de cada indicador a su factor.

2.Permita la correlación entre factores: asegúrese de que el modelo permita que los tres factores latentes covaríen libremente (modelo oblicuo). Esto refleja la hipótesis de que, si bien las capacidades son distintas, pueden estar correlacionadas entre sí en los modelos actuales.

3.Estime el modelo: dado que las puntuaciones de benchmark son variables continuas acotadas (0–100) y pueden presentar asimetría, utilice el estimador **MLR (Máxima Verosimilitud Robusta)**, que proporciona errores estándar y estadísticos de ajuste robustos ante desviaciones de la normalidad multivariada.

Evaluación y Conclusión

1. Bondad de Ajuste Global

•Reporte y evalúe los índices de ajuste robustos: χ^2 (Satorra-Bentler) y su p-valor, **RMSEA robusto** (con intervalo de confianza al 90%), **CFI robusto** y **SRMR**.

•¿El modelo teórico de tres factores se ajusta adecuadamente a los datos empíricos del Leaderboard? Utilice los criterios de referencia estándar ($RMSEA < 0.08$, $CFI > 0.90$, $SRMR < 0.08$) para emitir su juicio.

•En caso de ajuste insuficiente, explore los **índices de modificación** e interprete qué implicaría permitir las covarianzas de error sugeridas desde el punto de vista sustantivo.

2. Parámetros Locales

- Analice las **cargas factoriales estandarizadas** (λ). ¿Son todas estadísticamente significativas ($p < 0.05$)? ¿Sus magnitudes son suficientes ($\lambda > 0.40$) para considerar a cada benchmark un indicador válido de su constructo?
- Identifique el benchmark con la carga más baja dentro de cada factor. ¿Qué dice esto sobre su idoneidad como indicador de ese constructo latente?
- Examine las **correlaciones entre factores** ($\Phi_{12}, \Phi_{13}, \Phi_{23}$). ¿Cuál es la magnitud y dirección de la correlación entre F_{raz} y F_{ali} ? ¿Apoya esto la idea de que «hacer más inteligente» a un modelo y «alinearlo» son procesos independientes, o están acoplados en los modelos actuales?

3. Conclusión e Implicaciones para el Entrenamiento

Escriba una conclusión sobre si la teoría de los tres factores cognitivos (Razonamiento, Conocimiento y Alineamiento) es validada por los datos reales de evaluación del Open LLM Leaderboard. En su conclusión, discuta:

- ¿Qué implicaciones tiene la estructura factorial encontrada para el proceso de **fine-tuning selectivo** de un LLM como NLA-7B? Si los factores están altamente correlacionados, ¿es posible mejorar el alineamiento sin afectar el razonamiento?
- ¿Existe evidencia de **saturación de benchmarks** (benchmark saturation), es decir, indicadores que cargan sobre múltiples factores simultáneamente, sugiriendo que miden más de un constructo a la vez?
- ¿Qué benchmarks adicionales recomendaría incluir, o cuáles eliminaría, para obtener una batería de evaluación más psicométricamente sólida?

Situación 3

Una agencia de gestión agrícola necesita realizar una evaluación rápida del estado de la cobertura terrestre en una región vulnerable después de un evento climático extremo (e.g., sequía o inundación). No poseen etiquetas actualizadas (ground truth) de la zona, pero tienen acceso a miles de imágenes satelitales de alta resolución de la región.

El objetivo es utilizar **clustering** para agrupar estas imágenes en categorías (clústeres) que representen las diferentes *tipologías de cobertura terrestre* (e.g., cultivo saludable, bosque denso, suelo desnudo, zona inundada). Se hipotetiza que los clústeres que representen "suelo desnudo", "zona industrial" o "agua estancada" son indicadores de *zonas agroecológicas dañadas* o en estrés.

Fuente de Datos

- **Dataset: EuroSAT:** Land Use and Land Cover Classification with Sentinel-2
- **Descripción:** Este conjunto de datos contiene 27,000 imágenes satelitales (64x64 píxeles) tomadas por el satélite Sentinel-2.

- **Clases (Etiquetas):** Las imágenes están etiquetadas con 10 clases que usaremos *solo para la validación final*. Las clases incluyen:
 - AnnualCrop (Cultivo Anual)
 - PermanentCrop (Cultivo Permanente)
 - Pasture (Pasto)
 - Forest (Bosque)
 - HerbaceousVegetation (Vegetación Herbácea)
 - Industrial (Zona Industrial)
 - Residential (Zona Residencial)
 - SeaLake (Mar/Lago)
 - River (Río)

Modelado de Clustering

Aplique algoritmos de clustering sobre los datos reducidos ($n \times m$).

1. K-Means:
 - Determine el número óptimo de clústeres (k) utilizando el **método del codo (SSE)** y, más importante, el **Coeficiente de Silueta**.
 - Ajuste el modelo K-Means con la k óptima (e.g., $k=8$ a 12).
2. DBSCAN:
 - Aplique DBSCAN. Este método es robusto a los *outliers* y no requiere especificar k .
 - Justifique la elección de sus hiperparámetros (epsilon y min_samples).
 - ¿Cuántos clústeres encuentra DBSCAN? ¿Identifica muchas imágenes como "ruido" (anomalías)?

Evaluación y Perfilado (La Conexión Agroecológica)

1. **Validación Interna:** Reporte el **Coeficiente de Silueta** de su mejor modelo de clustering.
2. Validación Externa (Usando las Etiquetas Ocultas):
 - Ahora, y solo para validar, utilice las etiquetas reales del dataset EuroSAT (e.g., AnnualCrop, Industrial, etc.).
 - Genere una **matriz de confusión** cruzando sus k clústeres (Cluster 1, Cluster 2...) con las 10 clases reales.
 - Calcule métricas de validación externa como el **Adjusted Rand Index (ARI)** o **Normalized Mutual Information (NMI)** para medir qué tan bien su segmentación no supervisada coincide con la realidad.
3. Perfilado y Conclusión:

- Inspeccione la matriz de confusión. ¿Qué clases componen cada clúster?
- **Conclusión:** Identifique los clústeres que representan "zonas agroecológicas dañadas" o en estrés. ¿Son estos los clústeres que agruparon las imágenes de Industrial, SeaLake o Residential? ¿Creó el algoritmo un clúster separado para los Cultivos vs. Bosques?