

Sesión 2: PCA (Principal Component Analysis)

Reducción de la Dimensionalidad y PCA

Cristian E García

cegarcia@uao.edu.co

Maestría en Inteligencia Artificial y Ciencias de Datos
Facultad de Ingeniería
18 abr. 2026



Outline

1.Introducción

1.El problema y las soluciones

2.Representaciones Individuos Variables

1.Análisis nube de variables $\mathbb{R}^p$

2.Análisis nube de individuos $\mathbb{R}^n$

3.Interpretación de los Planos

3.Representación Simultanea

4.Elementos Suplementarios

5.Recostrucción

6.Ejemplos en Clase

Introducción

El PCA es la técnica del análisis multivariado más importante, fue presentado por primera vez por (Pearson, 1901) e integrado a la estadística matemática por (Hotelling, 1933).

El ACP es una técnica de representación de los datos, con un carácter óptimo según ciertos criterios algebraicos y geométricos, en donde se busca interpretar o comprender las relaciones entre variables y individuos en una matriz de datos $\mathbf{X}_{n \times p}$.

Introducción

Los objetivos del PCA son:

1. Comparar los individuos entre si. Las gráficas que se obtienen permiten observar la forma de la “nube de individuos”, lo que a su vez permite detectar patrones en ellos.
2. Describir las relaciones entre las variables.
3. Reducir la dimensión de la representación. A mayor relación entre las variables mayor es la capacidad de síntesis del PCA y unos pocos ejes factoriales podrán resumir las variables originales.

Introducción

Los objetivos del PCA son:

1. Comparar los individuos entre si. Las gráficas que se obtienen permiten observar la forma de la “nube de individuos”, lo que a su vez permite detectar patrones en ellos.
2. Describir las relaciones entre las variables.
3. Reducir la dimensión de la representación. A mayor relación entre las variables mayor es la capacidad de síntesis del PCA y unos pocos ejes factoriales podrán resumir las variables originales.

El PCA forma parte del **aprendizaje no supervisado**, y es importante para la **exploración y visualización de datos multivariados**. Su interpretación requiere tanto comprensión matemática como una lectura intuitiva de los resultados gráficos, facilitando la comparación entre individuos y variables.

Introducción

La Solución: Encontrar la Estructura Oculta con ACP

- PCA es una técnica de reducción de dimensionalidad no supervisada.
- **El objetivo:** Proyectar los datos a un espacio de menor dimensión maximizando la varianza de la información.
- La Intuición de las "Sombras":
 - Imagina tus datos como un objeto complejo en 3D.
 - El PCA encuentra los mejores ángulos para proyectar su "sombra" (representación 2D), capturando la silueta más informativa y característica.
 - Estas "direcciones óptimas" de proyección son los **Componentes Principales**.

Idea Intuitiva del PCA

Supongamos que tenemos la foto de un animal (pensando en $\mathbb{R}^3$). Lo que se quiere es encontrar una nueva foto donde tengamos **máxima información** del animal.



Idea Intuitiva del PCA

Realizamos una rotación (y traslación) de la foto en donde podamos **máximiz**ar la información (máximiz



PCA (Principal Component Analysis)

El **PCA** (*Principal Component Analysis*, Hotelling, 1933) es una técnica estadística que permite **reducir la dimensionalidad** de un conjunto de variables correlacionadas, transformándolas en **nuevas variables ortogonales** llamadas *componentes principales*.

- ☑ Cada componente explica una parte de la **variabilidad total** de los datos, ordenándose de mayor a menor varianza.
- ☑ De esta manera, el PCA “**descorrelaciona**” las variables originales y facilita su interpretación.
- ☑ Esta técnica se conoce también como la **transformada de Karhunen–Loève** o las **funciones ortogonales empíricas**, según el campo de aplicación.

PCA

Supongamos que el vector aleatorio r -dimensional

$$\mathbf{X} = (X_1, \dots, X_r)^\top$$

tiene una media $\boldsymbol{\mu}_X$ y una matriz de covarianzas $(r \times r)$ dada por Σ_{XX} . El Análisis de Componentes Principales (PCA) busca reemplazar el conjunto de r variables de entrada (no ordenadas y correlacionadas) $X_1, X_2, \dots, X_r$, por un conjunto (posiblemente más pequeño) de t proyecciones lineales (ordenadas y no correlacionadas)

$$\xi_1, \dots, \xi_t \quad (t \leq r)$$

De las variables originales, donde

$$\xi_j = \mathbf{b}_j^\top \mathbf{X} = b_{j1}X_1 + \cdots + b_{jr}X_r, \quad j = 1, 2, \dots, t,$$


se busca **minimizar la pérdida de información** debida a la sustitución.

En el PCA, la “información” se interpreta como la $\text{\textbf{variación total}}$ de las variables de entrada originales,


$$\sum_{j=1}^r \text{var}(X_j) = \text{tr}(\Sigma_{XX}).$$

A partir del **teorema de descomposición espectral**, se puede escribir:

$$\Sigma_{XX} = U\Lambda U^\top, \quad U^\top U = I_r,$$



(a)



(b)

$$\Sigma_{XX} = U\Lambda U^\top, \quad U^\top U = I_r,$$

donde la matriz diagonal Λ tiene como elementos diagonales los **autovalores** $\{\lambda_j\}$ de Σ_{XX} , y las columnas de U son los **autovectores** de Σ_{XX} .

Así, la variación total es:

$$\text{tr}(\Sigma_{XX}) = \text{tr}(\Lambda) = \sum_{j=1}^r \lambda_j.$$

El vector de coeficientes j -ésimo,

$$\mathbf{b}_j = (b_{1j}, \dots, b_{rj})^\top,$$

Se elige de modo que:

- ☑ Las primeras t proyecciones lineales $\xi_j, j = 1, 2, \dots, t$, de $\mathbf{X}$ estén **ordenadas por importancia** según sus varianzas $\{\text{var}(\xi_j)\}$, de mayor a menor:


$$\text{var}(\xi_1) \geq \text{var}(\xi_2) \geq \dots \geq \text{var}(\xi_t).$$

- ☑ Cada componente ξ_j es **no correlacionado** con los demás ξ_k cuando $k < j$.

Requisitos

Los únicos requerimientos previos para la aplicación del PCA son:

- a) Variables cuantitativas.
- b) Correlaciones lineales.
- c) La base de datos es completa, es decir no permite trabajar con datos faltantes.



Requisitos

El PCA tiene la opción de usar la matriz de correlaciones o la matriz de covarianzas.

1 Opción: Matriz de correlación. En esta opción se le esta dando la misma importancia a todas la variables y éstas tienen diferentes escalas de medida (metros, kg, minutos, etc).

2 Opción: Matriz de covarianzas. Esta opción se utiliza cuando todas las variables tienen la misma escala de medida, y el investigador quiere analizar las variables en función del grado de variabilidad (ej: calificaciones del semestre 1:5)

En la mayoría de casos se trabaja el **PCA normado** $\left(Z_i = \frac{X_{ij} - \mu_j}{\sigma_j} \right)$, análisis donde le damos la misma importancia a todas las variables de estudio.

Optimalidad de Mínimos Cuadrados del PCA

Existen dos derivaciones populares del conjunto de componentes principales de $\mathbf{X}$: el **PCA** puede derivarse utilizando un **criterio de optimalidad de mínimos cuadrados**, o bien puede obtenerse como una técnica de **maximización de la varianza**.

Optimalidad de Mínimos Cuadrados del PCA

Existen dos derivaciones populares del conjunto de componentes principales de $\mathbf{X}$: el **PCA** puede derivarse utilizando un **criterio de optimalidad de mínimos cuadrados**, o bien puede obtenerse como una técnica de **maximización de la varianza**.

Sea

$$\mathbf{B} = (\mathbf{b}_1, \dots, \mathbf{b}_t)^\top$$

una matriz de pesos de dimensión $(t \times r)$, con $t \leq r$.

Las proyecciones lineales dadas pueden escribirse como un vector t -dimensional:

$$\boldsymbol{\xi} = \mathbf{B}\mathbf{X}$$

donde $\boldsymbol{\xi}$ representa el conjunto de componentes principales resultantes de la combinación lineal de las variables originales.

Formulación de Mínimos Cuadrados en el ACP

Objetivo: Encontrar un modelo lineal que aproxime los datos originales $\mathbf{X}$ con el menor error posible.

$$\mathbf{X} \approx \boldsymbol{\mu} + \mathbf{A}\boldsymbol{\xi}, \quad \text{donde } \boldsymbol{\xi} = \mathbf{B}\mathbf{X}$$

Criterio de mínimos cuadrados:

$$\min_{\mathbf{A}, \mathbf{B}, \boldsymbol{\mu}} \mathbb{E}\{(\mathbf{X} - \boldsymbol{\mu} - \mathbf{A}\mathbf{B}\mathbf{X})^\top (\mathbf{X} - \boldsymbol{\mu} - \mathbf{A}\mathbf{B}\mathbf{X})\}$$

Interpretación:

- ☑ $\mathbf{A}$: direcciones principales (autovectores)
- ☑ $\boldsymbol{\xi}$: componentes principales (nuevas variables no correlacionadas)
- ☑ $\boldsymbol{\mu}$: vector de medias de las variables originales

El PCA busca las direcciones que minimizan el error de reconstrucción de los datos.

Solución y Significado del PCA

Solución óptima:

se obtiene mediante la descomposición espectral de la matriz de covarianzas

$$\Sigma_{XX} = U\Lambda U^\top$$

De donde:

$$\mathbf{A}^{(t)} = (\mathbf{v}_1, \dots, \mathbf{v}_t), \quad \mathbf{B}^{(t)} = \mathbf{A}^{(t)\top}, \quad \mathbf{C}^{(t)} = \sum_{j=1}^t \mathbf{v}_j \mathbf{v}_j^\top$$

Aproximación de rango t :

$$\widehat{\mathbf{X}}^{(t)} = \mu_X + \mathbf{C}^{(t)}(\mathbf{X} - \mu_X)$$

Solución y Significado del PCA

Interpretación geométrica:

- ✓ El ACP proyecta los datos sobre un subespacio de menor dimensión.
- ✓ Este subespacio preserva la **máxima varianza** y minimiza la **pérdida de información**.

El ACP combina reducción de dimensionalidad y reconstrucción óptima.

Interpretación del PCA: Proyecciones y Varianza

El PCA busca una reconstrucción de rango- t que minimice la pérdida de información.

$$\widehat{\mathbf{X}}^{(t)} = \boldsymbol{\mu}_X + \mathbf{C}^{(t)}(\mathbf{X} - \boldsymbol{\mu}_X) \quad \text{con} \quad \mathbf{C}^{(t)} = \sum_{j=1}^t \mathbf{v}_j \mathbf{v}_j^\top$$

El valor mínimo del criterio está dado por:

$$\sum_{j=t+1}^r \lambda_j,$$

la suma de los $r - t$ autovalores más pequeños de Σ_{XX} .

Interpretación del PCA: Proyecciones y Varianza

Interpretación geométrica:

Sea $V = (\mathbf{v}_1, \dots, \mathbf{v}_r)$ la matriz de autovectores de Σ_{XX} .

La reconstrucción de mínimos cuadrados de rango t se obtiene con dos transformaciones lineales:

$$\mathbb{R}^r \xrightarrow{L} \mathbb{R}^t \xrightarrow{L'} \mathbb{R}^r$$

donde L proyecta los datos y L' los reconstruye.

Propiedades:

$\text{cov}(\xi_i, \xi_j) = \lambda_j \delta_{ij}$ (son no correlacionados)

$\text{var}(\xi_j) = \lambda_j$ (cada componente explica varianza decreciente)

Componentes Principales y Varianza Explicada

Bondad del ajuste:

$$\text{Proporción no explicada} = \frac{\lambda_{t+1} + \dots + \lambda_r}{\lambda_1 + \dots + \lambda_r}$$

Cuanto menor sea esta razón, mayor es la varianza total explicada por los primeros t componentes.

Resultado adicional:

Las matrices $\boldsymbol{\mu}^{(t)}$, $\mathbf{A}^{(t)}$, $\mathbf{B}^{(t)}$ no solo minimizan el error cuadrático, sino también todas los **autovalores** de la matriz

$$\Psi^{(t)} = \mathbb{E}\{(\mathbf{X} - \boldsymbol{\mu} - \mathbf{A}\mathbf{B}\mathbf{X})(\mathbf{X} - \boldsymbol{\mu} - \mathbf{A}\mathbf{B}\mathbf{X})^\top\}.$$



Interpretación Geométrica del ACP

Proyección sobre subespacios:

- ✓ El ACP encuentra el **subespacio lineal de dimensión t** que mejor aproxima los datos originales.
- ✓ Cada componente principal define una **dirección ortogonal** que maximiza la varianza de los datos proyectados.
- ✓ La reconstrucción consiste en proyectar los puntos sobre ese plano y reexpresarlos en las coordenadas originales.


Interpretación Geométrica del ACP

La figura muestra la mejor aproximación lineal de rango 2 a un conjunto de datos en forma de semiesfera.



Los puntos proyectados (panel derecho) representan los datos en el espacio definido por los dos primeros componentes principales.

Ejemplo 1



Cada imagen puede representarse como un vector $\mathbf{x}_i \in \mathbb{R}^{256}$.

Se observa gran variación en el estilo de escritura, el grosor de los trazos y la **orientación**.

Ejemplo 1

Visualización de los dos primeros componentes principales:

$$\begin{aligned}\hat{f}(\lambda) &= \bar{x} + \lambda_1 v_1 + \lambda_2 v_2 \\ &= \text{3} + \lambda_1 \cdot \text{3} + \lambda_2 \cdot \text{3}.\end{aligned}$$



v_1 : movimiento horizontal — controla la **longitud de la parte inferior** del “3”.

v_2 : movimiento vertical — ajusta el **grosor y la inclinación** del trazo.

Análisis de varianza:


- ☑ Existen hasta **256 componentes** (una por píxel).
- ☑ Los primeros **50 componentes** explican $\approx 90\%$ de la variación total.
- ☑ Los primeros **12 componentes** explican $\approx 63\%$ de la variación.

Ejemplo 1




Ejemplo 2

rank 200




(a)

rank 2



(b)

rank 5



(c)


rank 20



(d)

Centrado de la nube de individuos


El centrado de los individuos permite trasladar el cero de la representación al centro de gravedad. En la gráfica centrada se pierden las coordenadas del centro de gravedad, por lo tanto, es necesario registrar esos valores, que son los promedios de las variables.



Distancia entre individuos

El parecido entre individuos en la tabla de datos se traslada a la representación geométrica como una distancia

$$d^2(i, l) = \sum_{j=1}^p (y_{ij} - y_{lj})^2$$



Ayudas a la interpretación de individuos

Entre los **ejes factoriales** de ambas nubes de puntos existen ciertas relaciones que permiten, conociendo las direcciones factoriales de un espacio, obtener las direcciones factoriales en el otro espacio.

A estas relaciones se les denomina **relaciones de transición**.

En la práctica, basta con realizar un solo ajuste por ejemplo, el de los **puntos-fila** y a partir de éste se obtienen los resultados para los puntos-columna.

En general, se realiza el ajuste de menor coste computacional, que corresponde a la nube de **puntos-fila**, ya que implica la diagonalización de una matriz de menores dimensiones.

La proyección de los puntos-fila sobre los ejes factoriales se obtiene mediante:

$$\varphi = \sqrt{\lambda} \mathbf{u}$$

Contribuciones

Contribución de un punto i a la formación del eje α :

$$CTR(i, \alpha) = \frac{p_i \psi_{i\alpha}^2}{\lambda_\alpha}$$

Las contribuciones permiten identificar los individuos que más influyen en la formación de los ejes factoriales. La suma de las contribuciones sobre todos los puntos es igual al 100%:

$$\sum_{i=1}^n CTR(i, \alpha) = 100$$

Interpretación:

- ✓ Un valor alto de $CTR(i, \alpha)$ indica que el punto i tiene un papel importante en la definición del eje α .
- ✓ Los puntos con baja contribución apenas influyen en la orientación del eje.

¡Veámoslo!

En



Aplicaciones

Ejemplo 1

El conjunto de datos **Wine**, disponible en la biblioteca `scikit-learn`, contiene mediciones químicas de diferentes muestras de vino provenientes de tres cultivares distintos de uva cultivados en Italia.

Cada vino se describe mediante **13 variables cuantitativas**, que incluyen:

```
Index(['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium',  
      'total_phenols', 'flavanoids', 'nonflavanoid_phenols',  
      'proanthocyanins', 'color_intensity', 'hue',  
      'od280/od315_of_diluted_wines', 'proline'],  
      dtype='object')
```

En total, se tienen **178 observaciones** correspondientes a vinos de **3 clases (cultivares)**.

Aplicaciones

Un equipo de investigación que se encarga de clasificar los tumores de pacientes en 3 subtipos. Dependiendo del subtipo, el paciente recibe una medicación diferente. El proceso de caracterización se hace mediante tinciones y observaciones al microscopio. Este proceso es muy laborioso y lento, lo que incrementa mucho el tiempo de respuesta de los médicos. Nuevos estudios apuntan a que cuantificando la expresión de un grupo de 9 genes se podría clasificar los tumores con una alta precisión. Se quiere determinar si tal patrón existe dentro de los datos.



¿Preguntas?