

Sesión 2: FA (Factor Analysis)

Análisis factorial Exploratorio y Confirmatorio

Cristian E García

cegarcia@uao.edu.co

Maestría en Inteligencia Artificial y Ciencias de Datos
Facultad de Ingeniería
2025



Outline

- 1.Introducción**
- 2. El Modelo**
- 3.El proceso Practico**
- 4. Aplicaciones**
- 5.Ejemplos en Clase**

Introducción

El **Análisis Factorial (AF)** nace en la **psicometría** a comienzos del siglo XX.

- **Charles Spearman (1904)** propuso la idea de un **factor general “g”** para explicar las correlaciones observadas entre pruebas de inteligencia.
- **Karl Pearson y Hotelling (1933)** extendieron las ideas de correlación y componentes principales, sentando las bases del AF moderno.

Desde entonces, el análisis factorial se ha convertido en una herramienta esencial en disciplinas tan diversas como:

- Psicología y educación (identificación de rasgos latentes)
- Economía y marketing (modelos de actitudes y preferencias)
- Biología y ciencias de datos (identificación de variables subyacentes o constructos ocultos)

Introducción

Objetivo fundamental

El objetivo del AF es **describir las correlaciones o covarianzas** entre un conjunto de variables observadas $X_1, X_2, \dots, X_p$ en términos de un número reducido de **factores comunes no observables** $F_1, F_2, \dots, F_m$, con $m < p$.

En palabras simples:

El AF busca descubrir las “dimensiones ocultas” que generan los patrones de correlación observados entre las variables.

Introducción

Motivación conceptual

En muchos conjuntos de datos multivariados:

- Las variables están altamente correlacionadas.
- Existen **constructos latentes** (por ejemplo: motivación, inteligencia, satisfacción) que **no se miden directamente**, pero que **influyen simultáneamente en varias variables observadas**.

El análisis factorial **resume la información y reduce la dimensionalidad** sin perder la estructura de interdependencia, permitiendo:

- Identificar **grupos de variables** que miden la misma dimensión.
- Simplificar modelos predictivos o explicativos.
- Validar escalas e instrumentos de medición.

Enfoque Matemático

El modelo factorial propone que cada variable observada X_i se puede expresar como una combinación lineal de factores comunes más un componente específico o error:

$$X_i = \mu_i + \lambda_{i1}F_1 + \lambda_{i2}F_2 + \dots + \lambda_{im}F_m + \varepsilon_i$$

En forma matricial, el modelo se escribe como:

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{LF} + \boldsymbol{\varepsilon}$$

Enfoque matemático

donde:

✱ $\mathbf{x} = (X_1, X_2, \dots, X_p)'$ es el vector de variables observadas.

✱ $\boldsymbol{\mu} = E(\mathbf{x})$ es el vector de medias.

✱ $\mathbf{L}$ es la matriz de **cargas factoriales** ($p \times m$), cuyos elementos λ_{ij} representan la relación entre la variable X_i y el factor común F_j .

✱ $\mathbf{F} = (F_1, F_2, \dots, F_m)'$ es el vector de **factores comunes** ($m \times 1$), variables no observables que explican la covarianza entre las X_i .

✱ $\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_p)'$ es el vector de **errores específicos** o factores únicos, independientes de los factores comunes.

Supuestos

El modelo supone que:

$$E(\mathbf{F}) = \mathbf{0}, \quad \text{Cov}(\mathbf{F}) = \mathbf{I}_m, \quad E(\boldsymbol{\varepsilon}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\varepsilon}) = \boldsymbol{\Psi}$$

donde $\boldsymbol{\Psi}$ es una matriz diagonal cuyos elementos ψ_i representan la varianza específica de cada variable X_i .

Bajo estos supuestos, la estructura de covarianza de X_i se expresa como:

$$\boldsymbol{\Sigma} = \text{Cov}(\mathbf{x}) = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$$

Supuestos

Esta descomposición muestra que la varianza total de cada variable se divide en:

Varianza común: $\mathbf{LL}'$, explicada por los factores comunes.

Varianza específica: Ψ , atribuida a factores únicos o error.

Por tanto, el modelo factorial proporciona una representación parsimoniosa de la covarianza entre variables observadas mediante un conjunto reducido de variables latentes no observables.

Enfoque robusto moderno

El modelo clásico de análisis factorial asume que las variables observadas provienen de una distribución normal multivariante y que la estructura de covarianza Σ puede ser estimada adecuadamente mediante la matriz de covarianza muestral. Sin embargo, en la práctica, estas condiciones rara vez se cumplen debido a la presencia de valores atípicos, distribuciones asimétricas o datos contaminados.

Enfoque robusto moderno

El **Análisis Factorial Robusto (RFA, por sus siglas en inglés)** extiende el modelo clásico con el objetivo de obtener estimaciones estables de los parámetros $\mathbf{L}$ y Ψ aun cuando los datos se apartan de los supuestos ideales de normalidad.

El modelo robusto mantiene la misma estructura fundamental:

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}' + \Psi$$

Enfoque robusto moderno

El **Análisis Factorial Robusto (RFA, por sus siglas en inglés)** extiende el modelo clásico con el objetivo de obtener estimaciones estables de los parámetros $\mathbf{L}$ y Ψ aun cuando los datos se apartan de los supuestos ideales de normalidad.

El modelo robusto mantiene la misma estructura fundamental:

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}' + \Psi$$

pero reemplaza la estimación clásica de $\boldsymbol{\Sigma}$ por un **estimador robusto de dispersión**, denotado como $\widehat{\boldsymbol{\Sigma}}_R$, de modo que:

$$\widehat{\boldsymbol{\Sigma}}_R = \mathbf{L}_R\mathbf{L}_R' + \Psi_R$$

Enfoque robusto moderno

Entre los estimadores robustos de dispersión más utilizados se encuentran:

- ✱ El **estimador MCD (Minimum Covariance Determinant)**, que busca el subconjunto de observaciones cuya covarianza tiene el determinante mínimo, proporcionando una estimación resistente de la matriz de covarianza.
- ✱ El **estimador OGK (Orthogonalized Gnanadesikan-Kettenring)**, basado en transformaciones robustas de pares de variables.
- ✱ Estimadores basados en **funciones de influencia limitada**, que reducen el impacto de valores extremos en la estimación de Σ .

Enfoque robusto moderno

La ventaja del enfoque robusto radica en que los **estimadores robustos de Σ** presentan una **función de influencia acotada**, lo que los hace menos sensibles a pequeñas contaminaciones en los datos. En consecuencia, las **cargas factoriales robustas $\mathbf{L}_R$** y las **varianzas específicas** resultan más estables y reflejan mejor la estructura latente de los datos.

Enfoque robusto moderno

En resumen, el análisis factorial robusto:

- ✱ Conserva la interpretación teórica del modelo factorial clásico.
- ✱ Mejora la estabilidad de los estimadores frente a datos contaminados.
- ✱ Permite inferir factores latentes bajo supuestos más realistas.

El tratamiento detallado de estos métodos puede consultarse en **Olive (2017)**, Robust Multivariate Analysis, Capítulo 11.

Modelo factorial y supuestos

Formulación general del modelo

Sea $\mathbf{x} = (X_1, X_2, \dots, X_p)'$ un vector aleatorio de dimensión p con media $\boldsymbol{\mu}$ y matriz de covarianza $\boldsymbol{\Sigma}$. El modelo factorial con m factores comunes ($m < p$) se define como:

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{LF} + \boldsymbol{\varepsilon},$$

Formulación general del modelo

donde:

✱ $\mathbf{F} = (F_1, F_2, \dots, F_m)'$ es el vector de **factores comunes** ($m \times 1$), variables no observables que explican la covarianza entre las X_i .

✱ $\mathbf{L} = (\lambda_{ij})$ es la **matriz de cargas factoriales** ($p \times m$), cuyos elementos λ_{ij} representan la relación lineal entre X_i y el factor F_j .

✱ $\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_p)'$ es el vector de **errores específicos** o *unicidades*, independientes de los factores comunes.

Cada variable observada X_i puede escribirse como:

$$X_i = \mu_i + \lambda_{i1}F_1 + \lambda_{i2}F_2 + \dots + \lambda_{im}F_m + \varepsilon_i.$$

Supuestos del modelo clásico

Se asume que:

$$\begin{aligned} E(\mathbf{F}) &= \mathbf{0}, & \text{Cov}(\mathbf{F}) &= \mathbf{I}_m, \\ E(\boldsymbol{\varepsilon}) &= \mathbf{0}, & \text{Cov}(\boldsymbol{\varepsilon}) &= \boldsymbol{\Psi} = \text{diag}(\psi_1, \psi_2, \dots, \psi_p), \\ & & \text{Cov}(\mathbf{F}, \boldsymbol{\varepsilon}) &= \mathbf{0}. \end{aligned}$$

Estas condiciones definen un **modelo factorial ortogonal**, en el que los factores son no correlacionados entre sí y los errores específicos son independientes de los factores y entre sí.

Bajo estos supuestos, la estructura de covarianza del vector $\mathbf{x}$ es:

$$\boldsymbol{\Sigma} = \text{Cov}(\mathbf{x}) = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}.$$

Propiedades fundamentales

✳ La covarianza entre $\mathbf{x}$ y $\mathbf{F}$ es:

$$\text{Cov}(\mathbf{x}, \mathbf{F}) = E[(\mathbf{x} - \boldsymbol{\mu})\mathbf{F}'] = \mathbf{L}.$$

✳ La varianza de cada variable observada X_i se descompone como:

$$\sigma_i^2 = \sum_{k=1}^m \lambda_{ik}^2 + \psi_i = h_i^2 + \psi_i,$$

donde:

✳ $h_i^2 = \sum_{k=1}^m \lambda_{ik}^2$ es la **comunalidad**, proporción de varianza explicada por los factores comunes.

✳ ψ_i es la **unicidad**, varianza específica de X_i no explicada por los factores.

Extensión robusta del modelo

El modelo robusto mantiene la estructura

$\Sigma = \mathbf{L}\mathbf{L}' + \Psi$, pero sustituye la matriz de covarianza clásica por un **estimador robusto de dispersión** $\widehat{\Sigma}_R$,

de modo que:

$$\widehat{\Sigma}_R = \mathbf{L}_R \mathbf{L}_R' + \Psi_R.$$

Extensión robusta del modelo

El modelo robusto mantiene la estructura

$\Sigma = \mathbf{L}\mathbf{L}' + \Psi$, pero sustituye la matriz de covarianza clásica por un **estimador robusto de dispersión** $\hat{\Sigma}_R$,

de modo que:

$$\hat{\Sigma}_R = \mathbf{L}_R \mathbf{L}_R' + \Psi_R.$$

Los supuestos de independencia permanecen, pero se eliminan las restricciones de normalidad multivariante. Los estimadores robustos más empleados son:

El **MCD (Minimum Covariance Determinant)**, que busca el subconjunto de observaciones con el determinante de covarianza mínimo.

El **(Orthogonalized Gnanadesikan--Kettenring)**, que estima la dispersión mediante covarianzas bivariadas robustas.

Extensión robusta del modelo

En este contexto, la matriz de cargas robustas $\mathbf{L}_R$ y la matriz de varianzas específicas robustas Ψ_R producen estimaciones menos sensibles a valores atípicos, manteniendo la interpretación del modelo factorial clásico.

Interpretación geométrica

En el espacio de las variables originales, cada factor define un eje que explica una parte de la variación común. Las variables con cargas elevadas sobre un mismo factor tienden a estar agrupadas, lo que permite interpretar los factores como ***dimensiones latentes*** o ***constructos subyacentes***.

El modelo robusto preserva esta interpretación, pero ajusta los ejes factoriales para evitar que valores extremos distorsionen la estructura geométrica de los datos.

Estimación de parámetros

El propósito de la estimación en el análisis factorial es encontrar matrices $\mathbf{L}$ (cargas factoriales) y $\mathbf{\Psi}$ (varianzas específicas) que reproduzcan lo mejor posible la matriz de covarianzas muestral $\mathbf{S}$ (o, en el caso robusto, su versión robusta $\widehat{\mathbf{\Sigma}}_R$), satisfaciendo la relación estructural:

$$\mathbf{S} \approx \mathbf{L}\mathbf{L}' + \mathbf{\Psi}.$$

Así, se busca minimizar la diferencia entre la matriz empírica y la que predice el modelo factorial:

$$\min_{\mathbf{L}, \mathbf{\Psi}} \|\mathbf{S} - (\mathbf{L}\mathbf{L}' + \mathbf{\Psi})\|.$$

Número de parámetros y parsimonia

La matriz de covarianza Σ contiene $p(p + 1)/2$ parámetros distintos, mientras que el modelo factorial requiere estimar $pm + p$ parámetros (las pm cargas factoriales y las p varianzas específicas). Cuando $m < p$, el modelo factorial impone una estructura más simple y parsimoniosa.

Parámetros modelo factorial: $pm + p$

Parámetros matriz completa: $\frac{p(p + 1)}{2}$

Número de parámetros y parsimonia

La matriz de covarianza Σ contiene $p(p + 1)/2$ parámetros distintos, mientras que el modelo factorial requiere estimar $pm + p$ parámetros (las pm cargas factoriales y las p varianzas específicas). Cuando $m < p$, el modelo factorial impone una estructura más simple y parsimoniosa.

Parámetros modelo factorial: $pm + p$

Parámetros matriz completa: $\frac{p(p + 1)}{2}$

Por ejemplo, si $p = 12$ y $m = 2$, entonces $\frac{p(p + 1)}{2} = 78$ parámetros se resumen mediante $pm + p = 36$ parámetros del modelo factorial.

Métodos clásicos de estimación

Los métodos tradicionales más empleados son:

1. Método de Componentes Principales (Principal Components, PC)

Se basa en la descomposición espectral de $\mathbf{S}$:

$$\mathbf{S} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}',$$

donde $\mathbf{\Lambda}$ contiene los autovalores y $\mathbf{V}$ los autovectores.

Se seleccionan los m mayores autovalores y sus vectores asociados para construir una primera estimación de $\mathbf{L}$.

2. Método de Ejes Principales (Principal Factor, PF):

Iterativo; comienza estimando las comunalidades h_i^2 , reemplazando los valores diagonales de $\mathbf{S}$ por h_i^2 y recalculando los autovalores hasta convergencia.

Métodos clásicos de estimación

3. Máxima Verosimilitud (Maximum Likelihood, ML):

Bajo el supuesto de normalidad multivariante:

$$\ell(\mathbf{L}, \mathbf{\Psi}) = -\frac{1}{2} \left[\log |\mathbf{L}\mathbf{L}' + \mathbf{\Psi}| + \text{tr}((\mathbf{L}\mathbf{L}' + \mathbf{\Psi})^{-1}\mathbf{S}) \right],$$

que se maximiza numéricamente respecto a $\mathbf{L}$ y $\mathbf{\Psi}$.

Permite realizar contrastes estadísticos sobre el número de factores m .

Consideraciones prácticas

- ✱ Para muestras limpias y grandes, los métodos clásicos (ML o PF) suelen ser suficientes.
- ✱ En presencia de valores atípicos, distribuciones sesgadas o colinealidad, es preferible un enfoque robusto (RFA).
- ✱ La elección del número de factores m puede realizarse mediante criterios como autovalores > 1 , gráfico de sedimentación o medidas robustas de varianza explicada.

En síntesis, el uso de estimadores robustos en análisis factorial combina la **flexibilidad estadística** con la **estabilidad numérica**, proporcionando inferencias más confiables en entornos reales donde los datos raramente siguen las condiciones ideales de la teoría clásica.

Estimación robusta (Olive, 2017)

El enfoque robusto busca obtener estimadores estables de $\mathbf{L}$ y Ψ reemplazando $\mathbf{S}$ por un estimador robusto de dispersión $\hat{\Sigma}_R$, tal que:

$$\hat{\Sigma}_R = \mathbf{L}_R \mathbf{L}_R' + \Psi_R.$$

Entre los métodos propuestos destacan:

RFA-MCD: utiliza el Minimum Covariance Determinant (MCD) para obtener $\hat{\Sigma}_R$ antes de aplicar la extracción factorial.

RFA-OGK: emplea el estimador OGK

(Orthogonalized Gnanadesikan-Kettenring), que es rápido y eficaz en altas dimensiones. Métodos basados en funciones de influencia acotada: limitan el efecto de cada observación en la estimación, mejorando la resistencia a outliers.

Evaluación e interpretación de resultados

Una vez estimadas las matrices de cargas factoriales $\mathbf{L}$ y de varianzas específicas Ψ , el paso siguiente consiste en evaluar la **calidad del modelo factorial** y la **interpretación de los factores**. Esto implica analizar:

- ✳ La proporción de varianza explicada por los factores comunes.
- ✳ Las comunalidades y unicidades de cada variable.
- ✳ Las cargas factoriales y su significado conceptual.
- ✳ La varianza total explicada por el modelo.

Comunalidades y unicidades

La **comunalidad** de la variable X_i mide la proporción de su varianza explicada por los factores comunes:

$$h_i^2 = \sum_{j=1}^m \lambda_{ij}^2.$$

La **unicidad** o varianza específica representa la parte no explicada por los factores comunes:

$$\psi_i = 1 - h_i^2.$$

Comunalidades y unicidades

La **comunalidad** de la variable X_i mide la proporción de su varianza explicada por los factores comunes:

$$h_i^2 = \sum_{j=1}^m \lambda_{ij}^2.$$

La **unicidad** o varianza específica representa la parte no explicada por los factores comunes:

$$\psi_i = 1 - h_i^2.$$

Interpretación práctica:

- ✻ Si h_i^2 es alto (> 0.7), la variable está bien representada por los factores.
- ✻ Si h_i^2 es bajo (< 0.4), la variable aporta poca información al modelo y podría considerarse para exclusión o reespecificación.

Varianza total explicada

La proporción de varianza común total explicada por los m factores es:

$$\text{Varianza explicada} = \frac{\sum_{j=1}^m \lambda_j}{\sum_{j=1}^p \lambda_j} \times 100 \% .$$

En términos matriciales, la varianza total explicada por los factores comunes se obtiene a partir de la traza de $\mathbf{LL}'$:

$$\text{Varianza explicada} = \frac{\text{tr}(\mathbf{LL}')} {\text{tr}(\mathbf{\Sigma})} .$$

Cargas factoriales e interpretación

Las cargas factoriales λ_{ij} representan la **correlación** entre la variable observada X_i y el factor común F_j . Valores grandes (en valor absoluto) indican una fuerte relación entre la variable y el factor.

Interpretación geométrica:

- ✱ Cada variable X_i se representa como un vector en el espacio de los factores comunes.
- ✱ El ángulo entre dos vectores refleja la correlación entre las variables.
- ✱ Variables agrupadas en la misma dirección se asocian al mismo factor.

Rotación factorial

La **rotación** de los factores tiene como objetivo facilitar la interpretación sin alterar la varianza total explicada.

- ✱ **Rotaciones ortogonales** (Varimax, Quartimax): preservan la independencia entre factores.
- ✱ **Rotaciones oblicuas** (Promax, Oblimin): permiten correlación entre factores.

Geométricamente, la rotación busca que las cargas factoriales se aproximen a 0 o a 1 en valor absoluto, clarificando qué variables pertenecen a cada factor.

Evaluación en el enfoque robusto

En el contexto robusto, la evaluación sigue los mismos principios, pero reemplazando $\mathbf{S}$ por el estimador robusto $\widehat{\boldsymbol{\Sigma}}_R$:

$$\widehat{\boldsymbol{\Sigma}}_R \approx \mathbf{L}_R \mathbf{L}_R' + \boldsymbol{\Psi}_R.$$

Se analizan:

- ✱ **Cargas robustas** $\mathbf{L}_R$: menos influenciadas por valores atípicos.
- ✱ **Comunalidades robustas** $h_{i,R}^2 = \sum_j \lambda_{ij,R}^2$.
- ✱ **Residuos robustos:**

$$\mathbf{E}_R = \widehat{\boldsymbol{\Sigma}}_R - (\mathbf{L}_R \mathbf{L}_R' + \boldsymbol{\Psi}_R),$$

cuya magnitud evalúa la adecuación del modelo robusto.

Evaluación en el enfoque robusto

La robustez se puede comprobar mediante:

- ✱ Comparación de cargas factoriales clásicas y robustas.
- ✱ Análisis de la ***función de influencia empírica*** (EIF), que identifica observaciones influyentes.
- ✱ Inspección visual de biplots robustos de individuos y variables.

Ejemplo de interpretación práctica

- ✳ **Variables con cargas altas en el mismo factor:** representan una misma dimensión latente (por ejemplo, “satisfacción” o “rendimiento”).
- ✳ **Factores con sentido conceptual:** se nombran según el patrón de las variables que más contribuyen.
- ✳ **Comunalidades bajas:** pueden sugerir ruido, errores de medición o variables irrelevantes.
- ✳ **Comparación robusta:** permite verificar si los patrones de carga se mantienen al eliminar el efecto de outliers o datos contaminados.

Selección del número de factores y validación del modelo

Importancia de la selección de m

El número de factores m determina la complejidad y capacidad explicativa del modelo. Un valor m demasiado pequeño genera un ajuste deficiente, mientras que un valor excesivo produce un modelo sobredimensionado y difícil de interpretar.

El objetivo es elegir m de forma que se logre un equilibrio entre:

- ✱ **Ajuste adecuado** a la estructura de covarianza observada.
- ✱ **Simplicidad interpretativa** (parsimonia).
- ✱ **Estabilidad numérica** y robustez frente a perturbaciones.

Criterios clásicos de selección

Criterio de autovalores mayores que uno (Kaiser, 1960):

Con base en la descomposición espectral de $\mathbf{S}$, se retienen los factores asociados a autovalores $\lambda_j > 1$, es decir:

$$m = \#\{j \mid \lambda_j > 1\}.$$

Este criterio es simple pero puede sobreestimar m cuando p es grande.

Gráfico de sedimentación (Scree Plot): Consiste en representar los autovalores λ_j en orden descendente. El número óptimo de factores se identifica en el “punto de inflexión” donde la curva deja de decrecer abruptamente.

Criterios clásicos de selección

Porcentaje de varianza explicada: Se elige el menor m tal que:

$$\frac{\sum_{j=1}^m \lambda_j}{\sum_{j=1}^p \lambda_j} \geq \tau,$$

con τ un umbral predefinido (comúnmente entre 70% y 90%).

Contraste de bondad de ajuste (ML): Para el modelo de máxima verosimilitud, se evalúa el estadístico:

$$\chi^2 = (n - 1) \left[\log |\mathbf{LL}' + \mathbf{\Psi}| + \text{tr}((\mathbf{LL}' + \mathbf{\Psi})^{-1} \mathbf{S}) - \log |\mathbf{S}| - p \right]$$

contrastando H_0 : “el modelo con m factores es adecuado”. Si $p > 0.05$, el número de factores retenidos es suficiente.

Enfoque robusto para la selección de factores

Cuando existen valores atípicos o distribuciones no normales, los autovalores de la matriz de covarianza muestral pueden estar distorsionados. Por ello, se recomienda emplear los autovalores de un **estimador robusto de dispersión** $\widehat{\Sigma}_R$.

$$\widehat{\Sigma}_R = \mathbf{L}_R \mathbf{L}_R' + \Psi_R, \quad \text{con autovalores } \lambda_{1,R} \geq \lambda_{2,R} \geq \dots \geq \lambda_{p,R}.$$

El número de factores robustos se determina mediante los mismos criterios, pero aplicados a los autovalores robustos $\lambda_{j,R}$. Esto evita la sobreestimación del número de factores causada por outliers.

¡Veámoslo!

En



Aplicacion 1

Ejemplo 1

En el análisis químico del vino, múltiples variables como alcohol, acidez, fenoles y color están fuertemente correlacionadas, lo que dificulta su interpretación directa. El objetivo del estudio es identificar un conjunto reducido de **factores latentes** que expliquen la variabilidad química y permitan una interpretación con sentido enológico (por ejemplo, factores asociados a fenoles, acidez o minerales). Dado que los datos pueden contener **valores atípicos** o desviarse de la normalidad, se compara el **análisis factorial clásico** con una versión **robusta**, evaluando la estabilidad de las cargas y la consistencia de la estructura latente frente a observaciones extremas.

Aplicacion 2

Caso de Estudio: EFA para *Feature Engineering* en Ruteo de Tickets de Soporte

El Contexto de Negocio: "SynthoDesk" (SaaS)

Empresa: "SynthoDesk", una plataforma SaaS B2B (Software as a Service) de gestión de proyectos.

Problema Crítico: Crecimiento explosivo. El volumen de tickets de soporte (N=2,000 / semana) ha desbordado al equipo de "Triage".

Proceso Actual (Manual): Un equipo (Nivel 1) lee y clasifica manualmente cada ticket para enrutarlo a uno de 4 departamentos:

1. Ingeniería (Bugs)
2. Facturación
3. Soporte de Producto (Usabilidad)
4. Gestión de Producto (*Feature Requests*)

Impacto (Pain Point): El ruteo manual es lento (horas de espera), costoso y propenso a errores, resultando en una baja satisfacción del cliente (↓CSAT).



¿Preguntas?