

Sesión 4: Análisis de Clustering

Métodos de agrupación Teoría y Métodos

Cristian E García

cegarcia@uao.edu.co

Maestría en Inteligencia Artificial y Ciencias de Datos

Facultad de Ingeniería

2 may. 2026



Outline

1. ¿En qué consiste el clustering?
2. Tipos de clusters
3. Funciones de distancia/similitud

Clustering

Propósito

- Agrupar los elementos de un conjunto en grupos (*cluster*) que tengan significado o sean útiles.

Pang-Ning Tan, Michael Steinbach, Vipin Kumar [1]

- La utilidad de los grupos de objetos depende del objetivo del análisis y del dominio de aplicación.
- En general, los grupos están formados por elementos similares o relacionados entre sí.

Clustering

Dificultades

- En aplicaciones prácticas es habitual que no exista una noción bien definida de cluster.
- En general, el **número de clusters es desconocido**, lo que supone una dificultad añadida.
- La noción de cluster está íntimamente relacionada con el concepto de **distancia o similitud**.
- La amplia variedad de aplicaciones y tipos de datos hace que existan **diferentes modelos y formas de agrupar** un conjunto de objetos.

Clustering

¿Cuántos grupos?




Figura 1: Datos originales.




Figura 2: Dos clusters.




Figura 3: Cuatro clusters.




Figura 4: Seis clusters.

Clustering

Tipos de clusters

- **Bien separados.** Los objetos de cada cluster están más cercanos (son más similares) a los objetos de su propio cluster que a los objetos de cualquier otro cluster.
- **Basados en prototipos.** Los objetos de cada cluster están más cercanos (son más similares) al prototipo que define al cluster que a los prototipos del resto de clusters.
- **Basados en densidad.** Un cluster es una región densa del espacio de objetos rodeada por una región de baja densidad.

Clustering

Tipos de clusters




Figura 5: Bien separados.




Figura 6: Basados en prototipos.




Figura 7: Basados en densidad.

Clustering

Funciones de distancia o similitud (i)

- **Atributos numéricos (i)**

Dados $x = (x_1, x_2, \dots, x_n)$ e $y = (y_1, y_2, \dots, y_n)$

- Distancia euclídea

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- Distancia rectilínea (o de Manhattan)

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Clustering

Funciones de distancia o similitud (ii)

- **Atributos numéricos (ii)**

- Distancia de Chebychev

$$d(x, y) = \max_{1 \leq i \leq n} |x_i - y_i|$$

- Distancia del coseno

$$d(x, y) = \arccos \frac{\sum_{i=1}^n x_i \cdot y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$$

Clustering

Funciones de distancia o similitud (iii)

- **Atributos numéricos (iii)**
 - Suele ser conveniente **normalizar** el valor de los atributos antes de calcular las distancias.
 - La normalización pretende evitar que la distancia se vea altamente influenciada por los atributos con valores altos.
 - Es conveniente también **detectar** previamente los **valores anómalos** o **atípicos** ya que estos suelen afectar gravemente a la normalización empleada.

Clustering

Funciones de distancia o similitud (iv)

- **Atributos nominales**

- Distancia

$$d(x, y) = \omega \sum_{i=1}^n \delta(x_i, y_i)$$

con

$$\delta(a, b) = \begin{cases} 0 & \text{si } a = b \\ 1 & \text{si } a \neq b \end{cases}$$

Clustering

Funciones de distancia o similitud (v)

- **Tiras de caracteres**

- Distancia de edición

Se ponderan las inserciones, borrados y sustituciones de caracteres necesarios para obtener una tira de caracteres desde la otra.

- **Conjuntos**

- Índice Jaccard

$$d(x, y) = \frac{|x \cup y| - |x \cap y|}{|x \cup y|}$$

Clustering Jerárquico

Clustering Jerarquico

Observaciones

- Una de las mayores dificultades al agrupar elementos es encontrar el **número apropiado de clusters**.
- Los métodos jerárquicos construyen una estructura en la que los elementos se **agrupan en subconjuntos cada vez mayores** hasta que todos pertenecen al mismo conjunto.
- De esta forma, no se muestra un agrupamiento sino las **relaciones de proximidad que existen entre los elementos**.


Clustering Jerarquico

Dendrograma (i)

- El clustering jerárquico suele representarse a través de un **dendograma**, que muestra en qué orden se han unido los cluster y cuál es el grado de proximidad que tienen los clusters que se unen.
- Los nodos hojas del dendograma se corresponden con los elementos individuales.
- En el nodo raíz se representa el cluster al que pertenecen todos los elementos.
- El resto de nodos se corresponde con los clusters que se van formando.


Clustering Jerarquico

Dendrograma (ii)



Clustering Jerarquico

Dendrograma. Cómo se construye



Clustering Jerarquico


Dendrograma. Cómo se genera un agrupamiento (i)

- El dendrograma puede usarse para **generar diferentes agrupamientos**.
- Para ello, **se selecciona un nivel y se poda el dendrograma** descartando los hijos de los nodos con nivel igual o superior al nivel seleccionado. Los nodos hojas del árbol resultante dan el agrupamiento buscado.
- Dependiendo del nivel seleccionado se obtienen agrupamientos con clusters más o menos compactos.

Clustering Jerarquico

Dendrograma. Cómo se genera un agrupamiento (ii)


- Nivel seleccionado = 6



Clustering Jerarquico

Dendrograma. Cómo se genera un agrupamiento (iii)

- Nivel seleccionado = 4



Clustering Jerarquico

Algorithm 1: Algoritmo aglomerativo básico

Matriz de proximidad

Obtener la proximidad entre cada par de elementos;

repeat

 Unir los dos clusters más próximos;

 Actualizar la matriz de proximidad;

until *Solo hay un cluster;*

Clustering Jerarquico

Medidas de proximidad entre clusters (i)

- **Enlace simple (single link).** La proximidad entre dos clusters se define como la **proximidad entre los dos elementos más próximos** que pertenecen a clusters diferentes.
- **Enlace completo (complete link).** La proximidad entre dos clusters se define como la **proximidad entre los dos elementos menos próximos** que pertenecen a clusters diferentes.
- **Promedio del grupo (group average).** La proximidad entre dos clusters se define como la **proximidad promedio entre todos los pares de elementos** que pertenecen a clusters diferentes.

Clustering Jerarquico

Medidas de proximidad entre clusters (ii)

- **Proximidad basada en centroides.** La proximidad entre dos clusters se define como la **proximidad entre los centroides de cada cluster**.
- Tras unir dos clusters debe obtenerse el centroide del nuevo cluster. Algunas alternativas para ello son:
 - Obtener el centroide como el **punto central del nuevo cluster**.
 - Obtener el centroide como la **suma ponderada de los centroides de los clusters** que se unen usando la siguiente expresión:

$$c = \left(\frac{N_1 \cdot x_1 + N_2 \cdot y_1}{N_1 + N_2}, \frac{N_1 \cdot x_2 + N_2 \cdot y_2}{N_1 + N_2}, \dots, \frac{N_1 \cdot x_n + N_2 \cdot y_n}{N_1 + N_2} \right)$$

con $(x_1, x_2, \dots, x_n)$ e $(y_1, y_2, \dots, y_n)$ los centroides de los clusters y N_1 e N_2 el número de elementos en cada uno de ellos.

Clustering Jerarquico

Método de Ward

- **Método de Ward.** La medida de proximidad usada es la suma de errores al cuadrado.

De esta manera, en cada etapa se unen los dos clusters que dan lugar al cluster con menor suma de errores al cuadrado.

Ejemplo Teórico

Clustering Jerarquico

Supongamos que contamos con cinco clientes y tenemos sus compras del año pasado en millones de dólares. La pregunta de negocio que queremos responder es: ¿cuántos tipos de clientes podemos identificar en los datos de tal manera que podamos segmentarlos y focalizar nuestras actividades de mercadeo?

Individuo (i)	Compras (Millones de pesos) ($x_{1,i}$)
1	10
2	7
3	28
4	20
5	35

$$d(x_i, x_j) = \sqrt{(x_{1,i} - x_{1,j})^2}$$

Clustering Jerarquico

$$d(x_i, x_j) = \sqrt{(x_{1,i} - x_{1,j})^2}$$

Individuo (<i>i</i>)	Compras (Millones de pesos) (<i>x</i> _{1,<i>i</i>})
1	10
2	7
3	28
4	20
5	35


Clustering Jerarquico

$$d(x_i, x_j) = \sqrt{(x_{1,i} - x_{1,j})^2}$$

Individuo (i)	Compras (Millones de pesos) ($x_{1,i}$)
1	10
2	7
3	28
4	20
5	35

i	1	2	3	4	5
1	0	3	18	10	25
2	3	0	21	13	28
3	18	21	0	8	7
4	10	13	8	0	15
5	25	28	7	15	0

Clustering Jerarquico



Paso 2	
Individuo (i)	Compras (Millones de pesos) ($x_{1,i}$)
1-2	7
3	28
4	20
5	35

Clustering Jerarquico

Paso 2

Individuo (i)	Compras (Millones de pesos) ($x_{1,i}$)
1-2	7
3	28
4	20
5	35


Clustering Jerarquico

Paso 2

Individuo (i)	Compras (Millones de pesos) ($x_{1,i}$)
1-2	7
3	28
4	20
5	35

i	1-2	3	4	5
1-2	3	0	21	13
3	21	0	8	7
4	13	8	0	15
5	28	7	15	0

Clustering Jerarquico



Clustering Jerarquico

Paso 3

Individuo (<i>i</i>)	Compras (Millones de pesos) ($x_{1,i}$)
1-2	7
3-5	28
4	20


Clustering Jerarquico

Paso 3


Individuo (i)	Compras (Millones de pesos) ($x_{1,i}$)
1-2	7
3-5	28
4	20

i	1-2	3-5	4
1-2	0	21	13
3-5	21	0	8
4	13	8	0

Clustering Jerarquico



Clustering Jerarquico



Ejercicio

Una empresa desea segmentar a sus clientes según el monto promedio de compras anuales (millones de pesos). Con los siguientes 7 clientes, determina cuántos segmentos hay.

1. Conforme el Dendograma y agrupe los clientes.

Cliente	Compras
1	4
2	7
3	8
4	18
5	20
6	33
7	37
8	40

Clustering basado en prototipos

Clustering basado en prototipos

Algoritmo K-means

- K-means [1] es un **algoritmo simple** con el que obtener clusters basados en prototipos (centroides).
- Consta de los siguientes pasos:
 - Sean dados K centroides iniciales.
 - Asignar cada punto al centroide más cercano. Los puntos asignados a un centroide forman un cluster.
 - Recalcular el centroide de cada cluster.
 - Repetir los anteriores dos pasos hasta que los puntos no cambien de cluster.

Clustering basado en prototipos

Algoritmo K-means. Ejemplo



Figura 1: Iteración 1.

Clustering basado en prototipos

Algoritmo K-means. Ejemplo



Figura 1: Iteración 1.

Clustering basado en prototipos

Algoritmo K-means. Ejemplo



Figura 1: Iteración 1.



Figura 2: Iteración 2.

Clustering basado en prototipos

Algoritmo K-means. Ejemplo




Figura 3: Iteración 3.



Figura 4: Iteración 4.

Clustering basado en prototipos

Algoritmo K-means. Observaciones

- En gran medida, el comportamiento del algoritmo K-means **depende de los centroides iniciales** elegidos.
- En general, suministra un agrupamiento que es **localmente óptimo**.
- La ejecución del algoritmo desde centroides iniciales distintos suministra agrupamientos distintos.

Clustering basado en prototipos

Calidad del clustering (i)

- Dados dos agrupamientos, ¿cuál es mejor?
- Si la distancia empleada es la euclídea, suele usarse como medida de calidad del agrupamiento la **suma de errores al cuadrado (SSE)**:

$$SSE = \sum_{i=1}^K \sum_{x \in C_i} (\text{dist}(c_i, x))^2$$

donde

$$c_i = \frac{1}{m_i} \sum_{x \in C_i} x$$

y m_i es el número de puntos que pertenecen al cluster C_i .

Clustering basado en prototipos

Calidad del clustering (ii)




Figura 5: $SSE = 23,772$



Figura 6: $SSE = 16,761$

Aplicaciones

¡Veámoslo!

En



uao

Aplicacion 1

Agrupar observaciones similares de iris usando variables continuas (largo/ancho de sépalos y pétalos) y caracterizar cada clúster. (Aunque el dataset tiene especies, se usan **solo para evaluar** al final: el entrenamiento es 100% no supervisado).

[Python](#)

[R-Studio](#)



¿Preguntas?